



背景: Inference: $x \rightarrow$ 有隱變量 \rightarrow 先驗 $p(x)$
 $\Rightarrow p(z|x)$



馬氏傳




$$\begin{aligned}
 &= \min_{z^*} p(z^*) Q(z^* \rightarrow z) \min_{z'} \left(\frac{p(z') Q(z \rightarrow z')}{p(z) Q(z' \rightarrow z)} \right) \\
 &= p(z^*) Q(z^* \rightarrow z) \cdot \alpha(z^*, z)
 \end{aligned}$$

MH 算法

likelyhood \times prior 似然乘以先验一次采样 ???
所以上面的商和结果就是前向的 $\hat{P}(z)$

$z^{(1)} \sim \hat{P}(z)$
 $\sim p(z)$

WiFi 机器学习-白板推导系列-蒙特卡洛方法 4 (Monte Carlo Method) -吉布斯采样 (Gibbs)



Gibbs: $p(z) = p(z_1, z_2, \dots, z_m)$, 固定其中的 z_i

边缘 $p(z_1, z_2, z_3)$

$p(z) = p(z_1, z_2, z_3)$ 丁鹤年

$z^{(1)}, z^{(2)}, z^{(3)}$ 初始值 在树中是相同的

$z^{(1)} \sim p(z_1 | z^{(2)}, z^{(3)})$ 但在这里 \rightarrow P 来采样

$z^{(2)} \sim p(z_2 | z^{(1)}, z^{(3)})$ 不同的链从不同的点开始 (山羊群是相同的)

$z^{(3)} \sim p(z_3 | z^{(1)}, z^{(2)})$

所以看, 以下针对的是哪个

$p(z_1 | z^{(2)}, z^{(3)})$ 证明 Gibbs 和 MH 相同

$p(z_1 | z^{(2)}, z^{(3)}) = \frac{p(z)}{\pi(z^{(2)}, z^{(3)})} \pi(z^{(2)}, z^{(3)})$ 有相同的先验

$p(z_1 | z^{(2)}, z^{(3)}) = \frac{p(z_1, z^{(2)}, z^{(3)})}{\pi(z^{(2)}, z^{(3)})} \pi(z^{(2)}, z^{(3)})$ 且先验是相同的, 所以表示的量是完全一样的

$= \frac{p(z_1, z^{(2)}, z^{(3)})}{p(z^{(2)}, z^{(3)})} \pi(z^{(2)}, z^{(3)})$

$= p(z_1) \pi(z^{(2)}, z^{(3)})$

$\Rightarrow \alpha = 1$ Gibbs 采样是特殊的 MH 算法

根据 Gibbs 的规定和定义 $\Rightarrow \alpha = 1$

第三节: Gibbs 采样即对上节内容的补充


Gibbs 采样是特殊的 MH 算法 \Leftrightarrow 把变量看成一个整体来采样

假设 $z = (z_1, z_2, z_3) = p(z_1) p(z_2) p(z_3)$

$dz = dz_1 dz_2 dz_3$

$\frac{1}{p(z)} = \frac{1}{p(z_1)} \frac{1}{p(z_2)} \frac{1}{p(z_3)}$

$= p(z_1) p(z_2) p(z_3)$



这样操作

MH 步骤 退一步想一想

Gibbs: $p(z | z_{-i})$ 把转移矩阵用自己的概率分布表示出来

假设现在看第 i 维 $Q(z \rightarrow z')$ Gibbs

$Q(z \rightarrow z') = \frac{p(z')}{p(z)}$

$= p(z_i) \rightarrow z_i^{(t+1)}$ 只看第 i 维的所有转移概率

不用别的 Q , 只看第 i 维的转移概率是固定的常数

① 回顾 MC 方法

② 根据以前的知识补充

① 采样的动机

① 采样本身就是常见的 (4类)

② 采样或积分

③ 什么是好的样本?

① 样本趋向于高概率区域。

② 样本之间相互独立

③ 采样是困难的. (the curse of high dimensionality)

① partition function is intractable 难计算

② high dimension

Monte Carlo Method

Rejection Sampling

Importance Sampling

MCMC

MH

Gibbs

① A: 在高维空间中随机抽样 $p(x)$

有可能从低维模型抽样再升维, 采样

例如 $p(x)$ 是一种生成模型高维数据, 低维

去生成新的数据, 如果模型参数固定, 采样数据

A: 求和, 求积的问题的简化

在前面的推导中已经会有求和的积分, 求积

② 采样方式, 特别是 MCMC

$\int p(x) f(x) dx = \frac{1}{N} \sum_{i=1}^N f(x^{(i)})$, 先采样再得到结果

Q2: A: 例: 从半球形分布 $p(x)$ 采样 x

从圆柱形分布 $p(x)$

人大代表: 抽取的范围太小, 不好采样

A) 样本之间相互独立，个人不同一个项，不同一个职业。

相关性太强可以视作是类目。

Q3 实操

① 无向图模型 P(D|E)

分销树状图。P(D|E) = $\prod_{i=1}^n P(D_i|E_i)$

如图：无向图模型。

② 直接材料 PDF \rightarrow CDF



很复杂的做不到。

③ 高维

$X \in \{1, 2, \dots, k\}^n$ n 个量共有 k^n 种状态空间，指数级别 \Rightarrow intractable

要通过特征通道高概率低概率 \Rightarrow 先有再采样取值

抽样可行

P7 P8 没有看