


# Gaussian network. 高斯网络或高斯图模型.

BN: bayesian network. MN: Markov Network. GN: Gaussian Network  
 PGM: 概率图模型. possibility. graphical model

PGM: { BN: (有向图. 贝叶斯网络) continuous. GN.  
 { MN: (马尔可夫随机场).

随机变量都是离散的. (BN, MN) discrete

如随机变量是连续的  $\rightarrow$  GN. { GBN.  
 { GMN.



$$x_i \sim N(\mu_i, \Sigma_i)$$

$X = (x_1, x_2, \dots, x_p)^T$  有  $p$  点.

$$p(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left\{-\frac{1}{2} (x-\mu)^T \Sigma^{-1} (x-\mu)\right\}$$

高斯网络是一个无向图  $\leftrightarrow$  对应的网络和高维高斯分布

每个点都是一维的随机变量.

$\downarrow$  分析  $\mu, \Sigma$ .

边缘分布是绝对独立.  
 如果是条件独立直接去加条件.  
 大部分看不能独立存在.

$$\Sigma = (\sigma_{ij}) = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & & \sigma_{2p} \\ \vdots & \vdots & & \vdots \\ \sigma_{p1} & \sigma_{p2} & \dots & \sigma_{pp} \end{pmatrix}_{p \times p}$$

$$x_i \perp x_j \Leftrightarrow \sigma_{ij} = 0$$

在高斯分布下成立.

$$\Lambda = \Sigma^{-1} = \begin{pmatrix} \lambda_{11} & \dots & \lambda_{1p} \\ \vdots & & \vdots \\ \lambda_{p1} & \dots & \lambda_{pp} \end{pmatrix}_{p \times p}$$

Multiple precision matrix is information matrix.

$$x_i \perp x_j | \{x_k, k \neq i, j\} \Leftrightarrow \lambda_{ij} = 0$$

要条件独立.

条件独立性:  $X_A \perp X_B \mid X_C$ . 如果没有条件独立性假设


⇒ 高斯图 ⇔ 高维高斯解

则图中的每点之间都有关系. ⇒ 完全图 没有意义.

第二讲.

高斯贝叶斯网络 → 连续型的PGM.

↪ 有向的: GBN.



GBN: is based on linear Gaussian Model.

↓ global Model.

↓ local Model.

$x_{pa(i)} = \text{Set}(x_1, \dots, x_p)$   $X = (x_1, \dots, x_p)^T$   $X \sim N(\mu, \Sigma)$

$p(x_i | x_{pa(i)}) = N(x_i | \mu_i + W_i^T x_{pa(i)}, \sigma_i^2)$

$x_i$ 是一维的.

$x_i = \mu_i + \sum_{j \in x_{pa(i)}} w_{ij} \cdot (x_j - \mu_j) + \sigma_i \cdot \varepsilon_i$

⇒  $x_i - \mu_i = \sum_{j \in x_{pa(i)}} w_{ij} \cdot (x_j - \mu_j) + \sigma_i \cdot \varepsilon_i$

$\boxed{x_i \sim N(\mu_i, \sigma_i^2)}$   $\mu = [\mu_1, \mu_2, \dots, \mu_p]^T$   $W = [w_{ij}]$   $\varepsilon = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_p)^T$

↑ 平稳-以0为均值的高斯分布 线性高斯模型

上面的可以写成:


⇒  $\boxed{X - \mu = W \cdot (X - \mu) + S \cdot \varepsilon}$

$S = \text{diag}(\sigma_i)$

局部:  $p(X) = N(\mu_x | \Sigma_x)$

$p(y | x) = N(y | Ax + b, \Sigma_y)$

数学基础中有 卡曼 filter. → 典型的高斯线性模型



$p(x_t | x_{t-1}) = p(x_t | A, B)$

$p(y_t | x_t) = p(y_t | C, D, R)$

↓ 独立表矩阵

$x_t = Ax_{t-1} + b + \varepsilon$  (满足随机变量  $\varepsilon \sim N(0, Q)$ )

$y_t = Cx_t + D + \sigma$  ( $\sigma \sim N(0, R)$ )

→ 特殊的 GBN. 只有一个父集.

$$(I - w) \cdot (x - \mu) = S \cdot \varepsilon \quad \text{转置} \quad \Sigma = wV(x) \cdot wV(x - \mu) = wV[I - w] \cdot S \cdot S^T$$

$$x - \mu = (I - w)^T \cdot S \cdot \varepsilon$$

断掉。

机器学习·高斯马尔科夫随机场

Gaussian Markov Network.

$$p(x) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} \cdot \exp\left[-\frac{1}{2} (x - \mu)^T \cdot \Sigma^{-1} \cdot (x - \mu)\right] \rightarrow \text{pdf.}$$